

# Análise de Séries Temporais: modelando a pandemia de Covid19\*

Dani Gamerman

Programa de PG em Estatística - UFMG

1o semestre de 2020

\* - motivado a partir de notas de José Marcos Andrade Figueiredo (UFMG)

# Modelo de crescimento logístico básico

$$Y(t) \sim N(\mu(t), \sigma^2) \quad , t = 1, 2, \dots$$

onde

$Y(t)$  é o numero de casos acumulados até o dia  $t$  em uma dada região ,

$$\mu(t) = \frac{a \exp \{ct\}}{1 + b \exp \{ct\}}$$

**Caso especial:**  $b = 0$  (crescimento exponencial)  $\Rightarrow \mu(t) = a \exp \{ct\}$

Adequado para os estágios iniciais da pandemia

Problemas do modelo básico:

- a) os dados são contagens e a distribuição normal pressupõe dados contínuos
- b) a variância deveria aumentar com a magnitude dos dados

# Características de interesse

As características mais importantes são:

## 1) Taxa de infecção

$c$  mede a velocidade da aceleração e reflete a taxa de infecção da doença

## 2) Assíntota

$$\lim_{t \rightarrow \infty} \mu(t) = \lim_{t \rightarrow \infty} \frac{a \exp \{ct\}}{1 + b \exp \{ct\}} = \frac{a}{b}$$

Reflete o total de casos acululados ao longo de toda a pandemia

Crescimento exponencial ( $b = 0$ ): assíntota =  $\infty$  !

## 3) Ponto de inflexão

É o tempo  $t^*$  onde o número de novos casos para de crescer e começa a diminuir

Crescimento exponencial ( $b = 0$ ): número de novos casos nunca para de crescer!

**4) Previsão:** O que podemos dizer sobre  $Y(t + k), \forall k$ , para  $t$  fixo (hoje)?

Depende da distribuição de  $Y(t)$  mas será sempre dada pela distribuição preditiva de  $Y(t + k)$  dado  $Y(1 : t) = \{Y(1), \dots, Y(t)\}$ , o que foi observado

Funciona como se fosse a distribuição a posteriori de  $Y(t + k)$

**Resultado útil:** Se  $Z$  e  $W$  são 2 v. a.'s quaisquer então

$$E[Z] = E[E(Z | W)]$$

$$Var[Z] = Var[E(Z | W)] + E[Var(Z | W)]$$

Em particular,  $E[Y(t + k) | Y(1 : t)] = E\{E[Y(t + k) | \mu(1 : t)] | Y(1 : t)\}$   
 $= E[\mu(t + k) | Y(1 : t)]$ , a média a posteriori de  $\mu(t + k)$

A inferência para tudo que foi dito acima deve ser reportada através de estimadores pontuais (ex: médias a posteriori), junto com os respectivos intervalos de credibilidade

## 5) Número de reprodutibilidade $R_0$

$R_0$  é o número esperado de casos secundários de uma doença produzidos por um indivíduo infectado

No tempo  $t$ , ele é definido como  $R_0 = \frac{\mu(t) - \mu(t-1)}{\mu(t-1)} = \frac{\mu(t)}{\mu(t-1)} - 1$

**Início da epidemia:**  $1 \gg b \exp \{ct\} \rightarrow \mu(t) \approx a \exp \{ct\} \rightarrow R_0 \approx e^c - 1$

**Final da epidemia:**  $1 \ll b \exp \{ct\} \rightarrow \mu(t) \approx a/b \rightarrow R_0 \approx 0$

**Meio da epidemia:**  $R_0$  é função dos parâmetros  $(a, b, c)$  e do tempo  $t$  e é dado por

$$R_0(t) = e^c \frac{1 + be^c e^{ct}}{1 + be^{ct}} - 1$$

Para cada  $t$  fixado podemos obter sua distribuição a posteriori (via amostra MCMC) e calcular média, quantis e intervalos de credibilidade


## 6) Número médio de novos casos (NMNC)

NMNC no tempo  $t+k$ :  $n_t(k) = E[Y(t+k) - Y(t+k-1)] = \mu(t+k) - \mu(t+k-1)$

Logo, NMNC também é função dos parâmetros  $(a, b, c)$  e pode ser facilmente calculado

Para cada  $t$  e  $k$  fixados podemos obter sua distribuição a posteriori (via amostra MCMC) e calcular média, quantis e intervalos de credibilidade

**Figure 5: Applying Italy/Europe as a Proxy for cases in Brazil**



Source: J.P. Morgan estimates.

⇒ estimativas e int. credibilidade para o ponto de inflexão e para o total de casos

# Alternativas

**1.1**  $Y(t) \sim \text{Poisson}(\mu(t))$  com  $E[Y(t)] = \mu(t)$  e  $\text{Var}(Y(t)) = \mu(t)$

**1.2**  $Y(t) \sim N(\mu(t), \sigma^2 \mu(t))$  com  $E[Y(t)] = \mu(t)$  e  $\text{Var}(Y(t)) = \sigma^2 \mu(t)$

Obs: modelo (1.2) admite sobredispersão se  $\sigma^2 > 1$

Alternativa (1.2) só cuida do comentário (b)

Alternativa (1.1) cuida dos 2 comentários mas não permite sobredispersão

# Poisson com sobredispersão

**1.3**  $Y(t) \mid \epsilon(t) \sim \text{Poisson}(\mu(t) + \epsilon(t))$  com  $E[\epsilon(t)] = 0$  e  $\text{Var}(\epsilon(t)) = \sigma^2$

**1.4**  $Y(t) \mid \epsilon(t) \sim \text{Poisson}(\mu(t) \times \epsilon(t))$  com  $E[\epsilon(t)] = 1$  e  $\text{Var}(\epsilon(t)) = \sigma^2$

Usando os resultados úteis anteriores  $\Rightarrow$

**Mod(1.3):**  $E[Y(t)] = E[E(Y(t) \mid \epsilon(t))] = E[\mu(t) + \epsilon(t)] = \mu(t) + E[\epsilon(t)] = \mu(t)$

$\text{Var}[Y(t)] = \text{Var}[E(Y(t) \mid \epsilon(t))] + E[\text{Var}(Y(t) \mid \epsilon(t))] = \text{Var}[\mu(t) + \epsilon(t)] + E[\mu(t) + \epsilon(t)] = \sigma^2 + \mu_t > \mu(t)$

**Mod(1.4):**  $E[Y(t)] = E[E(Y(t) \mid \epsilon(t))] = E[\mu(t) \times \epsilon(t)] = \mu(t) \times E[\epsilon(t)] = \mu(t)$

$\text{Var}[Y(t)] = \text{Var}[E(Y(t) \mid \epsilon(t))] + E[\text{Var}(Y(t) \mid \epsilon(t))] = \text{Var}[\mu(t) \times \epsilon(t)] + E[\mu(t) \times \epsilon(t)] = \mu_t^2 \sigma^2 + \mu_t > \mu(t)$

Ambos preservam média da Poisson e aumentam dispersão da Poisson



# Extensões dinâmicas

Modelos anteriores assumem comportamento estático  $\Rightarrow$

a forma da doença não se modifica ao longo do tempo  $\Rightarrow$

taxa de infecção será sempre a mesma, assintota será sempre a mesma, ...

**Modelos dinâmicos** flexibilizam isso

$$\mu(t) = \frac{a(t) \exp \{c(t) t\}}{1 + b(t) \exp \{c(t) t\}}$$

com

$$a(t) = a(t-1) + w_a(t), \text{ onde } w_a(t) \sim N(0, W_a), \forall t$$

$$b(t) = b(t-1) + w_b(t), \text{ onde } w_b(t) \sim N(0, W_b), \forall t$$

$$c(t) = c(t-1) + w_c(t), \text{ onde } w_c(t) \sim N(0, W_c), \forall t$$

## Vantagens:

- 1)  $E[a(t) \mid a(t-1)] = a(t-1)$  e o mesmo vale para  $b(t)$  e  $c(t) \Rightarrow$  constância local
- 2)  $Var[a(t) \mid a(t-1)] = W_a$  e o mesmo vale para  $b(t)$  e  $c(t) \Rightarrow$  aumento da incerteza

## Problemas:

- 1) variâncias  $W_a, W_b, W_c$  conhecidas  $\rightarrow$  difíceis de especificar
- 2) variâncias  $W_a, W_b, W_c$  desconhecidas  $\rightarrow$  difíceis de estimar
- 3) não dá para simplificar  $W_a = W_b = W_c = W$  (magnitudes diferentes de  $(a, b, c)$ )

Outra forma de introduzir dinamismo, agora multiplicativo

$$a(t) = a(t-1) \times w_a(t), \text{ onde } w_a(t) \sim \text{Gamma}(d_a, d_a), \forall t$$

$$b(t) = b(t-1) \times w_b(t), \text{ onde } w_b(t) \sim \text{Gamma}(d_b, d_b), \forall t$$

$$c(t) = c(t-1) \times w_c(t), \text{ onde } w_c(t) \sim \text{Gamma}(d_c, d_c), \forall t$$

## Vantagens:

- 1)  $E[a(t) \mid a(t-1)] = a(t-1)$  e o mesmo vale para  $b(t)$  e  $c(t) \Rightarrow$  constância local
- 2)  $Var[a(t) \mid a(t-1)] = d_c^{-1}$  e o mesmo vale para  $b(t)$  e  $c(t) \Rightarrow$  aumento da incerteza
- 3) Hiperparâmetros  $d_a, d_b, d_c$  fáceis de especificar

## Exemplos:

$$d = 1000 \rightarrow 0,90 = P(0,95 < w(t) < 1,05) = P\left(0,95 < \frac{a(t)}{a(t-1)} < 1,05\right)$$

$$d = 1500 \rightarrow 0,95 = P(0,95 < w(t) < 1,05) = P\left(0,95 < \frac{a(t)}{a(t-1)} < 1,05\right)$$

## Problemas:

- 1) As magnitudes de  $a, b, c$  ainda interferem no aumento da incerteza
- 2) não sei se software lida bem com Gammas tendo parâmetros tão altos

## Caso particular

Baseado em Gamerman, Santos e Franco (J. Time Series Analysis, 2013)

$$\mu(t) = \frac{a(t) \exp \{c t\}}{1 + b \exp \{c t\}}$$

$$a(t) = a(t-1) \times w_a(t), \text{ onde } w_a(t) \sim \text{Beta}, \forall t$$

Pode ser usado também para crescimento exponencial ( $b = 0$ )

### Vantagem:

Permite contas exatas, dispensando aproximações MCMC

### Desvantagem:

Não permite  $b$  e  $c$  dinâmicos

# Generalizações da logística

Até agora, usamos a logística para especificar a média  $\mu(t)$  como

$$\mu(t) = \frac{a \exp \{ct\}}{1 + b \exp \{ct\}} = \frac{a}{b + \exp \{-ct\}}$$

Essa expressão é a forma mais simples da logística

Ela pode ser generalizada de várias formas.

Uma possível forma da **logística generalizada** é

$$\mu(t) = d + \frac{a - d}{(b + \exp \{-ct\})^f}$$

A logística é obtida fazendo  $d = 0$  e  $f = 1$ .